Inteligência Artificial
Redes Madaline

Prof. Dr. Jefferson Beethoven Martins

IFTM Campus UPT – 03/03/2026

Rede Adaline

- Foi idealizada por Bernard Widrow e Marcian Hoff em 1960 (Multiple ADAptive LINear Elements).
- A aplicação principal era o chaveamento de circuitos telefônicos.
- Trata-se de uma rede de arquitetura simples, porém agregou uma nova técnica de treinamento com a utilização da regra Delta (Gradiente Descendente).
- Isso possibilitou a ampliação das aplicações em outros tipos de problemas, principalmente aqueles relacionados a sinais analógicos e consequentemente as primeiras aplicações industriais de RNAs.

Arquitetura Adaline

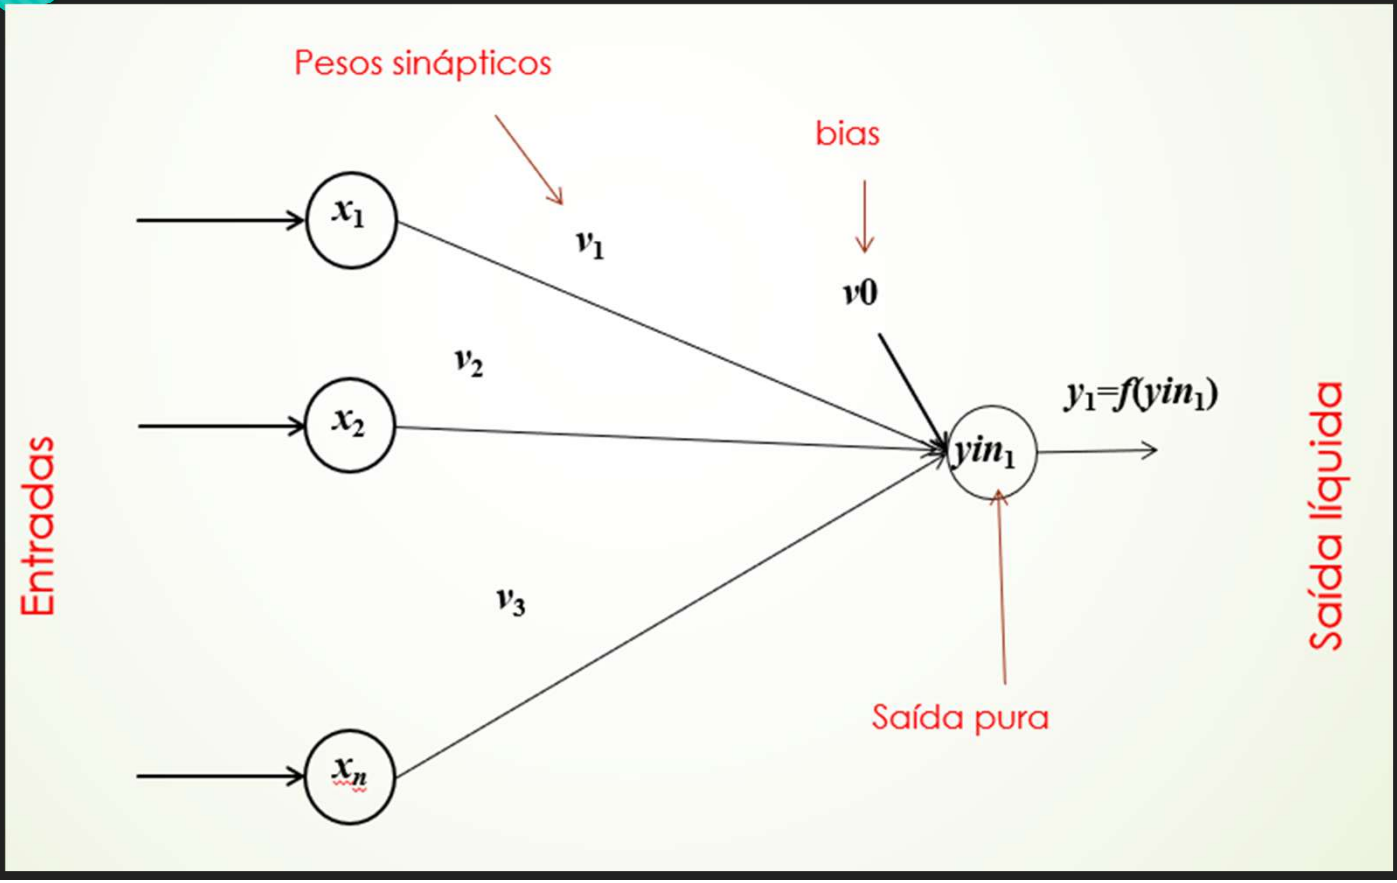

Arquitetura Madaline

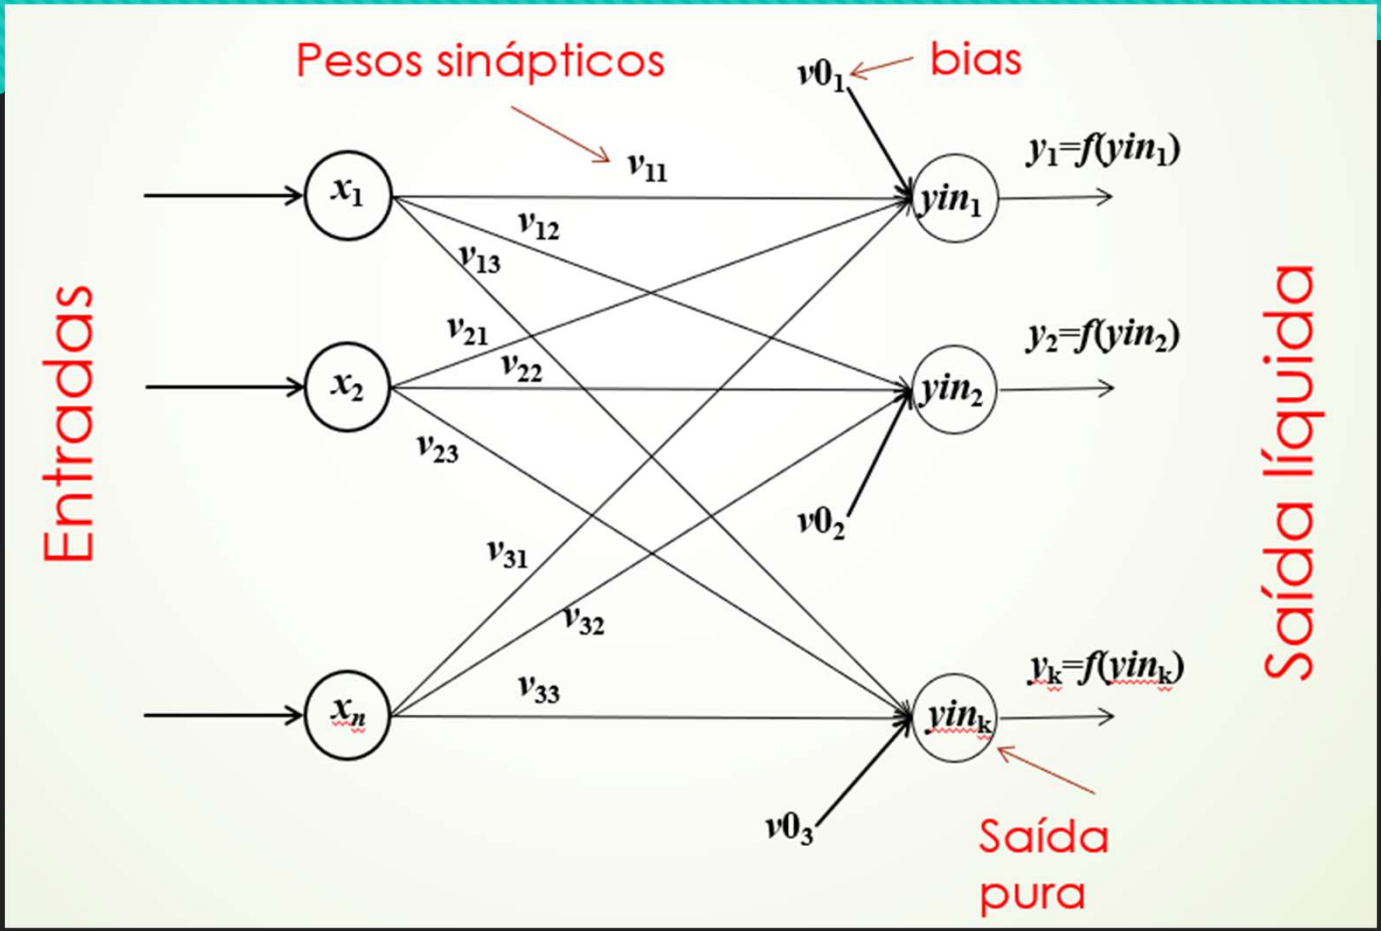

Aspectos gerais

- O treinamento pela regra Delta também é do tipo supervisionado.
- Pertence a arquitetura feedforward.
- É comumente empregada em problemas de reconhecimento de padrões.
- Assim como ocorre com a Rede Perceptron, a Adaline é capaz de reconhecer padrões pertencentes apenas a duas classes.
- No entanto, a Madaline permite a resolução de problemas onde se tenha mais do que duas classes de padrões.

Rede Adaline ou Madaline – do ponto de vista matemático

- Em termos matemáticos, a Rede Adaline é bem semelhante a Perceptron. Quando se trata da Rede Madaline, há acréscimo do índice da saída.

$$y_k = \begin{cases} 1, & se \ \sum v_{ik} \cdot x_i + b \geq \text{limiar} \\ 0, & se \ \sum v_{ik} \cdot x_i + b < \text{limiar} \end{cases}$$

OU

$$y_k = \begin{cases} 1, & se \ \sum v_{ik} \cdot x_i + b \geq \text{limiar} \\ -1, & se \ \sum v_{ik} \cdot x_i + b < \text{limiar} \end{cases}$$

Rede Adaline ou Madaline – do ponto de vista matemático

- O treinamento pela regra Delta usa o erro para o ajuste dos pesos sinápticos.

$$e = t - y$$

Rede Adaline – Parâmetros

Parâmetro	Representação	Tipo característico
Entradas	x_i	Reais ou binárias (pode ser necessário que sejam normalizados dependendo do problema
Pesos sinápticos	v_{ik}	Reais (aleatórios entre -0,5 e 0,5)
Bias	$v0_k$	Reais (aleatórios entre -0,5 e 0,5)
Saída pura	yin_k	Real – Resultado da adição entre o bias e a somatória dos produtos entre as entradas e seus respectivos pesos.
Função de ativação	$f(yin_k)$	Degrau ou Degrau Bipolar
Saída Líquida	y_k	Binária ou Bipolar
Processo de treinamento	---------	Supervisionado
Regra de Aprendizado	---------	Regra Delta

Rede Adaline – Fundamentação da fórmula de treinamento

- A regra Delta utiliza a aplicação do Gradiente Descendente.
- Esse método também é conhecido como algoritmo *LMS* (**L**east **M**ean **S**quare).
- O gradiente descendente é aplicado sobre a fórmula do erro para obter as fórmulas de atualização dos pesos sinápticos e do bias.

Rede Adaline – Fundamentação da fórmula de treinamento

- Considerando o erro proveniente da comparação entre as saídas geradas pela rede e as saídas esperadas (targets) é dado pela fórmula abaixo.

$$E(v) = \frac{1}{2}\sum_{i=1}^{k}\left(t^{(k)} - y\right)^2$$

- Substituímos a fórmula de cálculo do valor de y na expressão anterior.

$$E(v) = \frac{1}{2}\sum_{k=1}^{p}\left(t^{(k)} - \left(\sum v_{ip} \cdot x_i + b\right)\right)^2$$

$$E(v) = \frac{1}{2}\sum_{k=1}^{p}\left(t^{(k)} - \left(v^T \cdot x^{(k)} + b\right)\right)^2$$

Rede Adaline – Fundamentação da fórmula de treinamento

- A atualização dos pesos será dada por:

$$v^{novo} = v^{anterior} + \alpha \sum_{k=1}^{p} \left(t^{(k)} - y \right) \cdot x^{(k)}$$

- A atualização do bias será dada por:

$$v0^{novo} = v0^{anterior} + \alpha \sum_{k=1}^{p} \left(t^{(k)} - y \right)$$

Rede Adaline – Algor. de treinamento

1. Obter o conjunto de amostras de treinamento;
2. Associar a saída desejada $\left(t^{(k)}\right)$ para cada amostra obtida;
3. Iniciar os vetores v e b com valores aleatórios pequenos (entre $-0,5$ e $0,5$);
4. Escolher um valor para a taxa de aprendizagem α e a condição de parada;
5. Iniciar o contador de ciclos (épocas);
6. Repetir as instruções:

   6.1 Para cada amostra de treinamento $\left\{x^{(k)}, t^{(k)}\right\}$

   6.2 ciclo=ciclo+1

   6.3 E_{qt}=0;

   6.3.1 $yin = x^k \cdot v^T + v0$;

   6.3.2 $y = f(yin)$;

   6.3.3 $E_{qt} = E_{qt} + \frac{1}{2}\sum_{i=1}^{k}\left(t^{(k)} - y\right)^2$

   6.3.4 $v^{novo} = v^{anterior} + \alpha\sum_{k=1}^{p}\left(t^{(k)} - y\right) \cdot x^{(k)}$

   6.3.5 $v0^{novo} = v0^{anterior} + \alpha\sum_{k=1}^{p}\left(t^{(k)} - y\right)$

   Até que: a condição de parada seja satisfeita

Rede Adaline – Algoritmo de treinamento

- A condição de parada pode ser por alcance de determinado número de ciclos ou pelo alcance de um erro quadrático médio máximo.
- O valor da taxa de aprendizagem deve estar compreendido entre 0 e 1.
- Deve-se ter cuidado para o valor escolhido para a taxa de aprendizagem mesmo dentro do intervalo indicado.
- Um valor alto pode causar instabilidade na convergência do erro. Um valor extremamente baixo pode fazer com que a convergência seja muito lenta.

Regra One-of-Classes

- Até o momento trabalhamos com projetos em que havia apenas uma saída para a RNA.
- Redes Madaline podem ser utilizadas para resolver problemas com mais do que duas classes.
- Para resolver problemas dessa natureza, utiliza-se a regra One-of-Classes, que consiste em criar vetores com tamanho igual ao número de classes, em que a posição do componente 1 indica a classe do problema.
- O número de saídas da rede está diretamente ligado ao número de classes do problema. Se por exemplo a RNA for utilizada para reconhecer a foto de 4 pessoas, a rede deverá ter 4 saídas. E assim por diante...

Regra One-of-Classes – 5 classes

Classe 1	Classe 2	Classe 3	Classe 4	Classe 5
1	0	0	0	0
0	1	0	0	0
0	0	1	0	0
0	0	0	1	0
0	0	0	0	1

Classe 1	Classe 2	Classe 3	Classe 4	Classe 5
1	-1	-1	-1	-1
-1	1	-1	-1	-1
-1	-1	1	-1	-1
-1	-1	-1	1	-1
-1	-1	-1	-1	1

Eita... É Python

C:\Exemplo_Madaline\Madaline.py

temp.py × Madaline.py ×

```python
# -*- coding: utf-8 -*-
# Autor: Jefferson Beethoven Martins - adaptado de José Ricardo Gonçalves Manzan.
import os
import numpy as np
import random as rd

print("\x1b[2J\x1b[1;1H")
os.chdir(r'C:\Exemplo_Madaline')

entAux = np.loadtxt('Ent.txt')
(padroes, entradas) = np.shape(entAux)

targAux = np.loadtxt('Targ.csv', delimiter=';', skiprows=0)
(numSaidas, targets) = np.shape(targAux)

limiar = 0.0
alfa = 0.01
errotolerado = 0.01
v = np.zeros((entradas, numSaidas))
for i in range(entradas):
    for j in range(numSaidas):
        v[i][j] = rd.uniform(-0.1, 0.1)
```

C:\Exemplo_Madaline\Madaline.py

temp.py × Madaline.py ×

```python
v = np.zeros((entradas, numSaidas))
for i in range(entradas):
    for j in range(numSaidas):
        v[i][j] = rd.uniform(-0.1, 0.1)

v0 = np.zeros((numSaidas))
for j in range(numSaidas):
    v0[j] = rd.uniform(-0.1, 0.1)

yin = np.zeros((numSaidas))
y = np.zeros((numSaidas))

erro = 1.0
ciclo = 0

while erro > errotolerado and ciclo < 10000:
    ciclo = ciclo + 1
    erro = 0
    for i in range(padroes):
        padraoLetra = entAux[i, :]

        for m in range(numSaidas):
            soma = 0
            for n in range(entradas):
                soma = soma + padraoLetra[n] * v[n][m]
            yin[m] = soma + v0[m]

```

```python

        for j in range(numSaidas):
            if yin[j] >= limiar:
                y[j] = 1.0
            else:
                y[j] = -1.0

        for j in range(numSaidas):
            erro = erro + 0.5 * ((targAux[j][i] - y[j])**2)

        vanterior = v.copy()
        v0anterior = v0.copy()

        for m in range(entradas):
            for n in range(numSaidas):
                v[m][n] = vanterior[m][n] + alfa * (targAux[n][i] - y[n]) * padraoLetra[m]

        for j in range(numSaidas):
            v0[j] = v0anterior[j] + alfa * (targAux[j][i] - y[j])

    print(f"Ciclo: {ciclo} - Erro: {erro}")

# Rede treinada com sucesso.
entTeste = entAux[6, :]
for j in range(numSaidas):
    soma = 0
    for i in range(entradas):
        soma = soma + entTeste[i] * v[i][j]
    yin[j] = soma + v0[j]
```

Eita... É Python

```python

# Rede treinada com sucesso.
entTeste = entAux[6, :]
for j in range(numSaidas):
    soma = 0
    for i in range(entradas):
        soma = soma + entTeste[i] * v[i][j]
    yin[j] = soma + v0[j]

print("Yin final:", yin)
for j in range(numSaidas):
    if yin[j] >= limiar:
        y[j] = 1.0
    else:
        y[j] = -1.0
print("Y final:", y)
```

Mais um trabalho (trabalho 03)
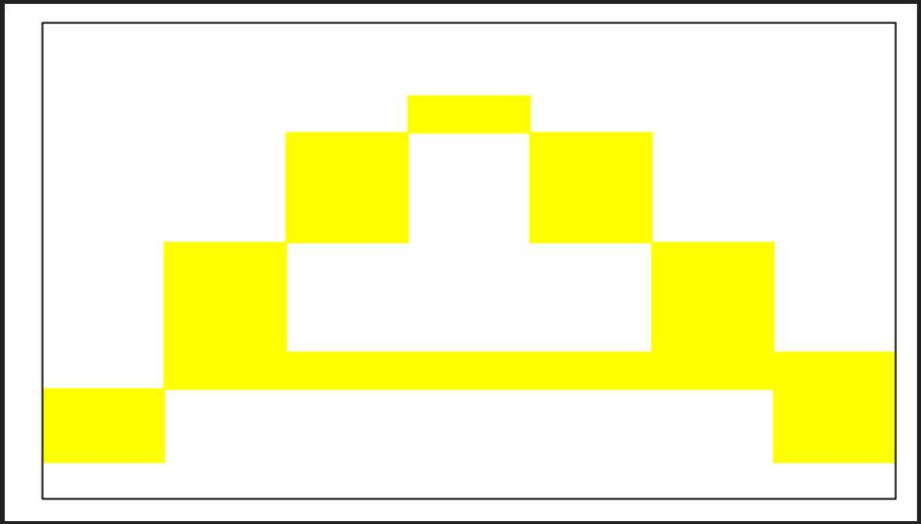
- Faça um programa que reconheça as 13 letras do alfabeto por meio de um algoritmo Madaline. O usuário deve construir as letras em uma interface visual (CheckBoxes).